

# Análisis exploratorio y auditoría de calidad de datos para la predicción de fuga y valor del cliente en una *fintech* colombiana: detección de fuga de información y columnas redundantes en un conjunto de 48.723 clientes

Valerie Martínez Pulido · Abrahan Basto Martínez · Rubén Esguerra Fernández

*Departamento de Matemáticas, Física y Ciencia de Datos,  
Universidad del Norte, Barranquilla, Colombia*

pmartinezv@uninorte.edu.co · abrahamb@uninorte.edu.co · esguerrar@uninorte.edu.co

*Curso de Machine Learning — Entrega 1: Análisis Exploratorio de Datos*

## Resumen

La predicción de la fuga de clientes y del valor del cliente son tareas centrales en los servicios financieros minoristas, y su resolución mediante aprendizaje supervisado depende críticamente de la calidad de los datos de entrada. En este trabajo se presenta la fase de comprensión y auditoría de datos de un proyecto de modelado sobre un conjunto de datos público de una empresa *fintech* colombiana correspondiente a 2023, compuesto por 48.723 clientes descritos con 54 variables y 3.159.157 transacciones individuales. Se realizó un análisis exploratorio exhaustivo que incluyó estadística descriptiva, análisis univariado y bivariado, correlaciones de Pearson y Spearman, cuantificación de valores atípicos, tamaños de efecto para variables categóricas y reconciliación de los resúmenes por cliente contra el detalle transaccional. La auditoría identificó tres problemas con impacto directo sobre el modelado. Primero, la variable objetivo de fuga resultó casi determinada por el número de productos activos, con una correlación de menos 0,876 y una escalera de paso exactamente constante de 0,05 que explica el 76,7 por ciento de su varianza, lo que evidencia una posible fuga de información. Segundo, tres columnas transaccionales resultaron duplicados desalineados o exactos: solo sus homólogas coinciden en el 100 por ciento con el detalle real, frente a un 0,1 a 1,1 por ciento de estas. Tercero, los faltantes de la utilización de crédito resultaron estrictamente estructurales. Como consecuencia directa se definió un conjunto depurado y un plan de preprocesamiento que constituye la base para la fase posterior de modelado.

**Palabras clave:** Análisis exploratorio de datos, Calidad de datos, Fuga de información, Predicción de fuga de clientes, Valor del cliente, Fintech

## 1 Introducción

La retención de clientes y la estimación de su valor son dos problemas centrales en la banca minorista y en el sector *fintech*. Adquirir un cliente nuevo resulta considerablemente más costoso que conservar uno existente, y el aporte económico de cada cliente a lo largo de su relación con la entidad es marcadamente heterogéneo, por lo que anticipar quién tiene mayor probabilidad de fuga (*churn*) y cuánto valor generará (*customer lifetime value*, CLV) permite focalizar las acciones comerciales donde tienen mayor impacto Gupta et al. [2006], Verbeke et al. [2012]. Ambas tareas se abordan habitualmente como problemas de aprendizaje supervisado: clasificación o regresión para la fuga, y regresión — o clasificación ordinal sobre segmentos de valor — para el CLV.

Sobre datos tabulares como los de este dominio, los modelos de referencia van desde alternativas lineales interpretables, como la regresión logística, hasta métodos de ensamble que constituyen el estándar actual, como *Random Forest* Breiman [2001] y *XGBoost* Chen and Guestrin [2016]. Estos algoritmos son robustos frente a variables heterogéneas y relaciones no lineales, y por ello son la elección natural para el modelado posterior de este proyecto. Sin embargo, su desempeño está condicionado por un factor previo a la elección del algoritmo: la calidad y la coherencia de los datos de entrada. Metodologías clásicas del área, como CRISP-DM Wirth and Hipp [2000], sitúan precisamente las fases de *comprensión* y *preparación* de los datos antes del modelado, y el análisis exploratorio de datos (EDA) en el sentido de Tukey Tukey [1977] es la herramienta para ejecutarlas.

Una limitación frecuente y a menudo subestimada en esta fase es la *fuga de información* (*data leakage*): cuando una variable predictora codifica, de forma directa o indirecta, la información de la etiqueta, las métricas de validación se inflan artificialmente y el modelo no generaliza a datos nuevos Kaufman et al. [2012]. A ello se suman problemas de calidad más prosaicos pero igualmente dañinos: columnas duplicadas o desalineadas que introducen multicolinealidad y ruido, y un tratamiento inadecuado de los valores faltantes, cuyo mecanismo generador — aleatorio o estructural — determina si imputar es legítimo o si equivale a inventar información Little and Rubin [2019]. Detectar estas condiciones *antes* de entrenar es, por tanto, tan determinante para el resultado final como la selección del modelo.

En este trabajo se aborda la fase de comprensión y preparación de datos de un proyecto de modelado sobre un conjunto público de clientes de una empresa *fintech* colombiana correspondiente al año 2023 Muñoz Guerrero et al. [2025], compuesto por 48.723 clientes descritos con 54 variables y 3.159.157 transacciones individuales, cuyas variables objetivo candidatas son la probabilidad de fuga (`churn_probability`) y el valor del cliente (`customer_lifetime_value` y su versión categórica `clv_segment`). El objetivo es doble: caracterizar el conjunto mediante un análisis exploratorio exhaustivo y auditar su calidad para definir un preprocesamiento riguroso y reproducible.

La contribución de esta primera entrega es la identificación cuantitativa de tres problemas con impacto directo sobre el modelado — una posible fuga de información en la etiqueta de churn, un grupo de columnas transaccionales duplicadas y desalineadas, y valores faltantes de naturaleza estructural — y la definición, como consecuencia directa de dichos hallazgos, de un conjunto de datos depurado y un plan de preprocesamiento. **Sostenemos que, sin esta auditoría previa, un modelo entrenado sobre los datos crudos alcanzaría un desempeño engañosamente alto, por la relación casi determinista entre la fuga y el número de productos activos, y arrastraría redundancia evitable; y mostramos con evidencia empírica las correcciones necesarias antes de la fase de modelado.**

## 2 Metodología

### 2.1 Descripción del problema y del conjunto de datos

#### (1) Descripción general

El conjunto de datos empleado es *COFINFAD: Colombian Fintech Financial Analytics Dataset*, publicado de forma abierta en el repositorio Mendeley Data bajo licencia Creative Commons Attribution 4.0 Muñoz Guerrero et al. [2025]. Corresponde a clientes de una empresa *fintech* colombiana durante los doce meses del año 2023 y se distribuye en dos archivos complementarios. La versión utilizada en este trabajo contiene 54 de las variables documentadas en el repositorio. El primero, `customer_data.csv`, contiene un registro por cliente: 48.723 filas y 54 columnas que combinan perfil demográfico, tenencia de productos, uso de canales digitales, satisfacción y NPS, resúmenes de

actividad transaccional y las variables objetivo. El segundo, `transactions_data.csv`, contiene el detalle individual de 3.159.157 transacciones con cuatro campos: `customer_id`, `date`, `amount` y `type`. La Tabla 1 resume la composición de la tabla de clientes por tipo de variable.

**Tabla 1:** Composición de la tabla de clientes por tipo de variable.

| Tipo          | Ejemplos                                                                         | Cantidad  |
|---------------|----------------------------------------------------------------------------------|-----------|
| Numéricas     | <code>age</code> , <code>active_products</code> , <code>churn_probability</code> | 28        |
| Catóricas     | <code>gender</code> , <code>location</code> , <code>income_bracket</code>        | 13        |
| Booleanas     | <code>savings_account</code> , <code>credit_card</code>                          | 7         |
| Fecha         | <code>first_transaction_date</code> , <code>last_survey_date</code>              | 5         |
| Identificador | <code>customer_id</code>                                                         | 1         |
| <b>Total</b>  |                                                                                  | <b>54</b> |

Se consideran dos variables objetivo. La primera, `churn_probability`, es una variable continua acotada al intervalo  $[0,11; 0,50]$  con media 0,343, susceptible de tratarse como regresión o, tras binarizarla por un umbral, como clasificación. La segunda, `customer_lifetime_value`, es continua, fuertemente asimétrica (mediana  $\approx 1,30 \times 10^8$  frente a media  $\approx 3,28 \times 10^8$  COP) y cuenta con una versión catórica ordinal, `clv_segment`, con cuatro niveles (*Bronze*, *Silver*, *Gold*, *Platinum*); el nivel más frecuente es *Bronze*, con 12.181 clientes (25,0 %), por lo que el balance entre segmentos es aproximadamente uniforme. Todos los clientes de la tabla poseen actividad transaccional registrada.

## (2) ETL (*Extract, Transform, Load*)

**Extract.** Los datos se obtuvieron en formato CSV desde la carpeta del proyecto. La tabla de clientes se carga directamente y la de transacciones se lee interpretando el campo `date` como tipo fecha, lo que habilita la agregación temporal posterior. Ambos archivos se leen con `pandas` en Python 3.

**Transform.** Las decisiones de limpieza no son *a priori*: se derivan de los hallazgos del EDA descritos en la Sección 2.2. En síntesis: (i) no se eliminan filas por duplicación en la tabla de clientes, pues no existen registros ni identificadores repetidos, mientras que en la tabla de transacciones se detectaron 102 filas exactamente duplicadas (0,003 % del total), volumen despreciable que se elimina por consistencia; (ii) se descartan tres columnas transaccionales identificadas como duplicados desalineados o redundantes (`average_transaction_value`, `total_transaction_volume` y `avg_daily_transactions`), conservando sus equivalentes verificadas contra el detalle de transacciones; (iii) los valores faltantes no se imputan con medidas de tendencia central, sino que se codifican mediante variables indicadoras `has_*` que preservan la información contenida en la ausencia, e imputando cero en la utilización de crédito únicamente para los clientes que poseen tarjeta; (iv) los valores atípicos de las variables monetarias no se eliminan, ya que corresponden a colas legítimas y no a errores de registro, y se prevé una transformación logarítmica  $\log(1 + x)$  para estabilizar la escala; y (v) las variables catóricas se codificarán mediante *one-hot* para las de baja cardinalidad y agrupación previa para `occupation` (35 niveles) y `location` (18 niveles).

**Load.** El resultado es un *dataframe* depurado, denominado `df_modelo`, de 48.723 filas y 54 columnas (51 columnas originales tras eliminar las tres redundantes, más las tres indicadoras `has_*`),

almacenado como tabla lista para el modelado. Para la fase siguiente se prevé una partición estratificada en entrenamiento y prueba con semilla aleatoria fija (`seed=42`) a fin de garantizar la reproducibilidad de los resultados.

### (3) EDA exhaustivo

Por su extensión, el análisis exploratorio de datos — tercera componente de esta subsección — se desarrolla de forma independiente en la Sección 2.2.

## 2.2 Análisis exploratorio de datos (EDA exhaustivo)

Esta sección desarrolla el análisis exploratorio exhaustivo correspondiente a la componente (3) de la Sección 2.1. Se organiza en estadística descriptiva, análisis univariado, análisis bivariado y de correlación, detección de atípicos, auditoría de calidad y comportamiento transaccional, y cierra con las decisiones de preprocesamiento que se derivan directamente de lo observado.

### 2.2.1 Estadística descriptiva

La Tabla 2 presenta los estadísticos de las variables numéricas más relevantes. Se observan tres comportamientos distintos: variables acotadas en rangos estrechos (edad, antigüedad), variables de escala monetaria con dispersión extrema (volumen y valor de transacción, CLV) y variables de satisfacción concentradas en pocos valores.

**Tabla 2:** Estadísticos descriptivos de variables numéricas seleccionadas ( $n = 48.723$ ).


| Variable                | Media              | Desv. est.         | Mín.               | Mediana            | Máx.                  |
|-------------------------|--------------------|--------------------|--------------------|--------------------|-----------------------|
| age                     | 44,54              | 12,28              | 29,00              | 45,00              | 60,00                 |
| household_size          | 3,50               | 1,58               | 1,00               | 3,00               | 13,00                 |
| active_products         | 2,10               | 1,18               | 1,00               | 2,00               | 5,00                  |
| app_logins_frequency    | 22,38              | 11,75              | 4,00               | 22,00              | 100,00                |
| satisfaction_score      | 4,16               | 0,58               | 2,00               | 4,00               | 6,00                  |
| nps_score               | -26,76             | 12,56              | -80,00             | -28,00             | 23,00                 |
| customer_tenure         | 11,37              | 0,72               | 4,70               | 11,63              | 11,97                 |
| tx_count                | 64,84              | 611,93             | 10,00              | 18,00              | 77.465,00             |
| avg_tx_value            | $3,56 \times 10^6$ | $3,96 \times 10^6$ | $3,18 \times 10^5$ | $1,76 \times 10^6$ | $5,17 \times 10^7$    |
| total_tx_volume         | $2,57 \times 10^8$ | $6,21 \times 10^9$ | $3,18 \times 10^6$ | $4,81 \times 10^7$ | $1,07 \times 10^{12}$ |
| churn_probability       | 0,343              | 0,07               | 0,11               | 0,35               | 0,50                  |
| customer_lifetime_value | $3,28 \times 10^8$ | $7,93 \times 10^8$ | 0,00               | $1,30 \times 10^8$ | $1,78 \times 10^{10}$ |

La distancia entre media y mediana en las variables monetarias — en `total_tx_volume` la media quintuplica a la mediana — anticipa la fuerte asimetría a la derecha que se confirma en el análisis univariado. En sentido contrario, `customer_tenure` presenta una desviación estándar de apenas 0,72 sobre un máximo de 11,97, indicando una concentración casi total de los clientes en el mismo rango de antigüedad.


### 2.2.2 Análisis univariado

La Figura 1 presenta la distribución de las principales variables numéricas. Las variables monetarias exhiben colas largas hacia la derecha que comprimen la mayor parte de la masa de probabilidad

contra el eje; por ello la Figura 2 las reexpresa en escala logarítmica mediante diagramas de caja, donde su estructura y su dispersión resultan legibles.




**Fig. 1:** Distribución de las principales variables numéricas de la tabla de clientes.




**Fig. 2:** Variables monetarias en escala logarítmica  $\log(1 + x)$ . La longitud de los bigotes evidencia la asimetría remanente incluso tras la transformación.

La distribución de `churn_probability` (Figura 9, izquierda) es unimodal y aproximadamente simétrica en torno a 0,35, pero truncada en ambos extremos: no existen clientes con probabilidad inferior a 0,11 ni superior a 0,50. Esta ausencia de valores en las regiones extremas es la primera señal de que la variable no registra un evento de fuga observado, sino un puntaje previamente calculado. El CLV (Figura 12, izquierda), en escala logarítmica, se aproxima a una distribución normal, comportamiento característico de las variables log-normales propias de magnitudes monetarias.


Respecto de las variables categóricas (Figura 3), el género se reparte de forma casi equilibrada (24.033 mujeres, 49,3 %) y el sentimiento del *feedback* es mayoritariamente positivo (38.897 clientes, 79,8 %). Entre las variables de alta cardinalidad (Figuras 4 y 5), Bogotá concentra 16.967 clientes (34,8 %), mientras que `occupation` distribuye 48.723 clientes entre 35 niveles con una frecuencia máxima de apenas 1.456 casos (3,0 %), lo que la convierte en una variable de escaso poder discriminativo en su forma actual.



**Fig. 3:** Frecuencias de las variables categóricas de baja cardinalidad.




**Fig. 4:** Quince ocupaciones más frecuentes. La frecuencia máxima no alcanza el 3% del total.



**Fig. 5:** Quince ubicaciones más frecuentes, encabezadas por Bogotá con el 34,8 % de los clientes.

La tenencia de productos (Figura 6) es marcadamente desigual: la cuenta de ahorros alcanza al 78,9 % de los clientes y el pago de facturas al 70,1 %, mientras que el producto de seguros solo llega al 21,2 %. Esta variable resultará central en el análisis de la fuga.




**Fig. 6:** Tasa de tenencia o adopción por producto financiero.

### 2.2.3 Valores faltantes y su mecanismo

Los valores ausentes se concentran en únicamente tres columnas (Figura 7 y Tabla 3); las 51 restantes están completas.





**Fig. 7:** Porcentaje de valores faltantes por columna. Solo tres variables presentan ausencias.

**Tabla 3:** Columnas con valores faltantes y mecanismo identificado.

| Columna                  | Faltantes | %    | Mecanismo                                 |
|--------------------------|-----------|------|-------------------------------------------|
| complaint_topics         | 24.346    | 50,0 | No explicado por las variables examinadas |
| credit_utilization_ratio | 18.263    | 37,5 | Estructural: ausente si no posee tarjeta  |
| feature_requests         | 16.115    | 33,1 | No explicado por las variables examinadas |

El contraste de cada columna contra una variable que pudiera explicar la ausencia arroja un resultado concluyente para `credit_utilization_ratio`: la tabla de contingencia frente a `credit_card` es perfecta, ya que el 100 % de los registros con valor ausente corresponde a clientes sin tarjeta de crédito y el 100 % de los registros informados corresponde a clientes con tarjeta. Se trata, por tanto, de un faltante estrictamente estructural, cuyo significado es “no aplica” y no “dato perdido”. En cambio, `complaint_topics` y `feature_requests` no muestran relación con las variables de referencia examinadas — el promedio de `support_tickets_count` es idéntico (1,0) entre registros con y sin queja informada, y el de `feature_usage_diversity` también coincide (2,37) — por lo que su ausencia se comporta como aproximadamente aleatoria. Esta distinción es relevante porque implica tratamientos diferentes: imputar cero en la utilización de crédito es correcto solo para quienes poseen tarjeta, mientras que para las otras dos columnas la decisión defendible es conservar la indicadora de presencia y evitar imputaciones que no tienen respaldo en los datos.

#### 2.2.4 Auditoría de columnas transaccionales redundantes

El conjunto incluye dos grupos de columnas que resumen la actividad transaccional de cada cliente. Una comparación directa muestra que ninguno de los tres pares principales coincide fila a fila, resultado que en principio sugeriría que miden magnitudes distintas. Sin embargo, al comparar además sus distribuciones como conjuntos de valores ordenados, el diagnóstico cambia por completo (Tabla 4).

**Tabla 4:** Diagnóstico de los pares de columnas transaccionales. La columna “mismos valores” compara ambas series tras ordenarlas.

| Par de columnas                                | Coinciden<br>por fila (%) | Mismos<br>valores (%) | Diagnóstico               |
|------------------------------------------------|---------------------------|-----------------------|---------------------------|
| avg_tx_value / average_transaction_value       | 0,0                       | 100,0                 | Duplicado desalineado     |
| total_tx_volume / total_transaction_volume     | 0,0                       | 100,0                 | Duplicado desalineado     |
| tx_count / monthly_transaction_count           | 0,0                       | 0,0                   | Distinta ventana temporal |
| transaction_frequency / avg_daily_transactions | 100,0                     | 100,0                 | Duplicado exacto          |

Los dos primeros pares contienen exactamente el mismo conjunto de valores — coincidencia del 100 % al ordenarlos — pero ninguna correspondencia a nivel de fila. La única explicación consistente con ambos hechos es que se trata de la misma variable cuyo orden fue alterado respecto de los identificadores de cliente: un duplicado corrupto, no una medida alternativa. El cuarto par es un duplicado exacto y alineado, redundante por definición. El tercero, en cambio, corresponde a la misma magnitud expresada en una ventana temporal distinta. Este diagnóstico se verifica de forma independiente en la Sección 2.2.10 contra el detalle real de transacciones.

Consistentemente, el análisis de multicolinealidad (Tabla 5) identifica un bloque de tres variables mutuamente idénticas y un par de variables de satisfacción fuertemente asociadas.

**Tabla 5:** Pares de variables numéricas con correlación  $|r| > 0,9$ .

| Variable A                | Variable B             | $r$   |
|---------------------------|------------------------|-------|
| transaction_frequency     | avg_daily_transactions | 1,000 |
| monthly_transaction_count | avg_daily_transactions | 1,000 |
| monthly_transaction_count | transaction_frequency  | 1,000 |
| satisfaction_score        | nps_score              | 0,917 |

### 2.2.5 Rangos acotados

Varias variables presentan límites que resultan difíciles de atribuir a un proceso natural de registro (Tabla 6).

**Tabla 6:** Rangos observados en variables con acotamiento sospechoso.

| Variable           | Mín.  | P1    | P99   | Máx.  |
|--------------------|-------|-------|-------|-------|
| age                | 29,00 | 29,00 | 60,00 | 60,00 |
| churn_probability  | 0,11  | 0,17  | 0,46  | 0,50  |
| customer_tenure    | 4,70  | 8,63  | 11,97 | 11,97 |
| satisfaction_score | 2,00  | 3,00  | 5,00  | 6,00  |

La edad se restringe exactamente al intervalo de 29 a 60 años, sin un solo cliente fuera de él, y la antigüedad se satura en 11,97 tanto en el percentil 99 como en el máximo. Que una probabilidad no alcance nunca los extremos 0 y 1 refuerza la interpretación de `churn_probability` como un puntaje derivado. En conjunto, estos patrones sugieren que el conjunto es al menos parcialmente sintético, lo que obliga a ser prudente al extrapolar conclusiones fuera de los rangos observados. Finalmente, se

registra un único cliente con CLV exactamente igual a cero (0,002 % del total), volumen irrelevante que no compromete el análisis.

### 2.2.6 Valores atípicos

La cuantificación mediante la regla del rango intercuartílico con factor 1,5 (Tabla 7) confirma lo anticipado por los diagramas de caja.


**Tabla 7:** Variables con mayor proporción de valores atípicos (regla IQR 1,5×).

| Variable                  | Atípicos | %    |
|---------------------------|----------|------|
| failed_transactions       | 8.818    | 18,1 |
| monthly_transaction_count | 6.394    | 13,1 |
| transaction_frequency     | 5.889    | 12,1 |
| avg_daily_transactions    | 5.889    | 12,1 |
| tx_satisfaction           | 5.783    | 11,9 |
| tx_count                  | 5.783    | 11,9 |

Estos valores no corresponden a errores de captura sino a colas legítimas de distribuciones asimétricas: en `failed_transactions`, por ejemplo, la mediana y ambos cuartiles valen cero, de modo que cualquier cliente con al menos una transacción fallida es marcado como atípico por construcción de la regla. Eliminar estas observaciones supondría descartar precisamente a los clientes más activos y a los que experimentan incidencias, que son informativos para ambos objetivos. La decisión adoptada es conservarlos y aplicar transformación logarítmica a las variables de escala monetaria.

### 2.2.7 Análisis bivariado y de correlación

La matriz de correlación de Pearson (Figura 8) resume las asociaciones lineales entre las 28 variables numéricas. Destacan tanto los bloques de variables transaccionales mutuamente redundantes ya identificados como una asociación aislada y muy intensa con la variable objetivo de fuga.



**Fig. 8:** Matriz de correlación de Pearson de las variables numéricas.

Dado el fuerte sesgo de las variables monetarias, la Tabla 8 contrasta el coeficiente de Pearson con el de Spearman, que captura relaciones monótonas no necesariamente lineales.

**Tabla 8:** Principales asociaciones con cada variable objetivo: Pearson frente a Spearman.


| Variable                           | Pearson | Spearman    |
|------------------------------------|---------|-------------|
| <i>Con churn_probability</i>       |         |             |
| active_products                    | −0,88   | −0,84       |
| app_logins_frequency               | −0,26   | −0,28       |
| age                                | 0,21    | 0,21        |
| satisfaction_score                 | −0,18   | −0,19       |
| nps_score                          | −0,17   | −0,16       |
| <i>Con customer_lifetime_value</i> |         |             |
| total_tx_volume                    | 0,11    | <b>0,98</b> |
| avg_tx_value                       | 0,34    | 0,76        |
| tx_satisfaction                    | 0,61    | 0,56        |
| tx_count                           | 0,16    | 0,56        |

El contraste es revelador para el CLV. La correlación de Pearson con `total_tx_volume` es de apenas 0,11, lo que sugeriría una relación débil; sin embargo, el coeficiente de Spearman asciende a 0,98, es decir, una relación monótona prácticamente perfecta. La discrepancia se explica por la extrema asimetría de ambas variables: unos pocos valores muy grandes dominan el cálculo lineal y enmascaran una relación de rango casi determinista. Esta observación tiene una consecuencia metodológica directa: en escala logarítmica, el volumen transaccionado debería ser un predictor muy potente del CLV, y evaluar la asociación únicamente con Pearson habría llevado a descartarlo erróneamente.


En cuanto a las variables categóricas, la asociación medida mediante la  $V$  de Cramér resulta baja en general, con dos excepciones moderadas: `income_bracket` con `education_level` ( $V = 0,38$ ) y `customer_segment` con `clv_segment` ( $V = 0,38$ ); esta última es esperable, pues ambas describen la intensidad de la relación comercial. El resto de los pares presenta valores iguales o cercanos a cero, lo que indica independencia y descarta redundancia entre las categóricas.

### 2.2.8 Variable objetivo I: probabilidad de fuga

La Figura 9 muestra la distribución de la fuga y su comportamiento por segmento de cliente, y la Figura 10 la fuga promedio según la tenencia de cada producto.



**Fig. 9:** Distribución de `churn_probability` (izquierda) y su comportamiento por segmento de cliente (derecha).



**Fig. 10:** Fuga promedio según la tenencia de cada producto. En todos los casos, poseer el producto se asocia con menor fuga.


El hallazgo central del análisis surge al desagregar la fuga por el número de productos activos (Tabla 9). La relación no es simplemente fuerte: es una escalera de paso constante.

**Tabla 9:** Fuga promedio según el número de productos activos.

| Productos activos | Media | Desv. est. | Clientes | $\Delta$ media |
|-------------------|-------|------------|----------|----------------|
| 1                 | 0,40  | 0,03       | 19.576   | —              |
| 2                 | 0,35  | 0,03       | 14.653   | −0,05          |
| 3                 | 0,30  | 0,03       | 7.197    | −0,05          |
| 4                 | 0,25  | 0,03       | 4.871    | −0,05          |
| 5                 | 0,20  | 0,03       | 2.426    | −0,05          |

Cada producto adicional reduce la fuga promedio exactamente en 0,05, con una desviación estándar constante de 0,03 en los cinco grupos. La correlación entre ambas variables es  $r = -0,876$ , de modo que un único predictor explica el  $R^2 = 0,767$  de la varianza de la etiqueta. Una regularidad de esta naturaleza — paso idéntico, dispersión idéntica — no es propia de un fenómeno de comportamiento observado, en el que cabría esperar efectos decrecientes y varianza heterogénea entre grupos. La interpretación más plausible es que `churn_probability` fue *generada* a partir de `active_products` mediante una regla determinista más un término de ruido de escala reducida. Combinado con el acotamiento del rango documentado antes, ello configura un caso de fuga de información: entrenar un modelo que incluya `active_products` produciría métricas excelentes que no reflejarían capacidad predictiva real sino la recuperación de la fórmula generadora Kaufman et al. [2012].

Las restantes variables presentan asociaciones débiles pero coherentes con la teoría (Figura 11): a mayor satisfacción y mayor NPS, menor fuga. Las variables categóricas, evaluadas mediante el tamaño de efecto  $\eta^2$  (Tabla 10), explican una fracción prácticamente nula de la varianza.



**Fig. 11:** Fuga frente a la satisfacción declarada (izquierda) y al NPS (derecha).


**Tabla 10:** Tamaño de efecto  $\eta^2$  de las variables categóricas sobre la fuga.

| Variable categórica        | $\eta^2$ |
|----------------------------|----------|
| income_bracket             | 0,0050   |
| location                   | 0,0004   |
| education_level            | 0,0002   |
| preferred_transaction_type | 0,0001   |
| customer_segment           | 0,0001   |
| acquisition_channel        | 0,0000   |

Ninguna categórica supera el 0,5 % de varianza explicada, lo que confirma que el perfil demográfico y el canal de adquisición aportan una señal marginal frente al número de productos.

### 2.2.9 Variable objetivo II: valor del cliente

El CLV, representado en escala logarítmica (Figura 12), presenta una distribución aproximadamente log-normal y una progresión ordenada a lo largo de los segmentos de valor.




**Fig. 12:** Distribución de  $\log(1 + \text{CLV})$  (izquierda) y CLV por segmento de valor en escala logarítmica (derecha).

**Tabla 11:** CLV mediano por segmento de valor y por segmento de cliente (COP).

| clv_segment | CLV mediano        | customer_segment | CLV mediano        |
|-------------|--------------------|------------------|--------------------|
| Bronze      | $4,11 \times 10^7$ | inactive         | $3,15 \times 10^7$ |
| Silver      | $9,58 \times 10^7$ | occasional       | $8,80 \times 10^7$ |
| Gold        | $1,91 \times 10^8$ | regular          | $2,36 \times 10^8$ |
| Platinum    | $4,93 \times 10^8$ | power            | $5,34 \times 10^8$ |


La progresión es monótona y de gran amplitud en ambas particiones: el CLV mediano se multiplica por doce entre *Bronze* y *Platinum*, y por diecisiete entre los clientes inactivos y los de mayor actividad (Tabla 11). El tamaño de efecto de `clv_segment` sobre el CLV es  $\eta^2 = 0,194$ , muy superior al de cualquier categórica sobre la fuga.

Resulta notable, en contraste, que el CLV mediano *no* varíe con el número de productos activos (Figura 13, izquierda): permanece en torno a  $1,29 \times 10^8$  para clientes con uno a cuatro productos y solo asciende levemente a  $1,38 \times 10^8$  con cinco. Es decir, la variable que casi determina la fuga carece de relación con el valor del cliente. El CLV se explica por la intensidad transaccional — como muestra el panel derecho de la Figura 13 y confirma el coeficiente de Spearman de 0,98 con el volumen — y no por la amplitud de la relación comercial. Ambos objetivos responden, por tanto, a mecanismos distintos, y la Figura 14 lo corrobora: la correlación entre fuga y CLV es prácticamente nula ( $r = -0,02$ ).



**Fig. 13:** CLV por número de productos activos (izquierda) y frente al volumen total transaccionado (derecha), ambos en escala logarítmica.





**Fig. 14:** Relación entre las dos variables objetivo. La ausencia de estructura confirma su independencia.

### 2.2.10 Comportamiento transaccional


La tabla de transacciones cubre del 4 de enero al 29 de diciembre de 2023 y registra actividad para la totalidad de los 48.723 clientes. Su composición por tipo de operación aparece en la Tabla 12.

**Tabla 12:** Composición de las transacciones por tipo de operación.


| Tipo         | Cantidad         | Participación (%) |
|--------------|------------------|-------------------|
| Transfer     | 1.433.963        | 45,4              |
| Payment      | 970.548          | 30,7              |
| Withdrawal   | 456.577          | 14,5              |
| Deposit      | 298.069          | 9,4               |
| <b>Total</b> | <b>3.159.157</b> | <b>100,0</b>      |

La auditoría de calidad de esta tabla arroja 102 filas exactamente duplicadas (0,003 %), ningún monto menor o igual a cero, ninguna fecha nula, ningún cliente huérfano sin perfil asociado y ningún cliente sin transacciones. Cabe señalar que el signo de la operación reside exclusivamente en el campo `type`, dado que todos los montos son positivos; calcular flujos netos exigirá aplicar el signo correspondiente según el tipo.


Los montos por tipo de operación (Figura 15) presentan distribuciones similares entre sí en escala logarítmica. La evolución mensual (Figura 16) es estable, sin tendencia ni estacionalidad marcada, y la distribución por día de la semana (Figura 17) es homogénea, sin la caída de fin de semana que cabría esperar en datos financieros reales — observación coherente con la naturaleza parcialmente sintética del conjunto.



**Fig. 15:** Distribución del monto por tipo de transacción en escala logarítmica.



**Fig. 16:** Evolución mensual del número de transacciones y del volumen monetario.




**Fig. 17:** Transacciones por día de la semana y composición mensual por tipo de operación.

El aporte decisivo de esta tabla es que permite verificar de forma independiente los resúmenes por cliente. Agregando el detalle real por `customer_id` y comparándolo con cada columna reportada se obtiene la Tabla 13.

**Tabla 13:** Reconciliación de las columnas reportadas contra el detalle real de transacciones.

| Columna reportada         | Magnitud real           | Coincidencia (%) | Veredicto |
|---------------------------|-------------------------|------------------|-----------|
| tx_count                  | Número de transacciones | 100,0            | Confiable |
| total_tx_volume           | Suma de montos          | 100,0            | Confiable |
| avg_tx_value              | Monto promedio          | 100,0            | Confiable |
| monthly_transaction_count | Número de transacciones | 0,1              | Descartar |
| total_transaction_volume  | Suma de montos          | 0,4              | Descartar |
| average_transaction_value | Monto promedio          | 1,1              | Descartar |

El resultado es inequívoco y confirma el diagnóstico de la Tabla 4: las tres columnas del primer grupo reproducen exactamente la agregación del detalle transaccional, mientras que sus homólogas del segundo grupo apenas coinciden en un 0,1 a 1,1 % de los casos, porcentaje atribuible a coincidencias fortuitas. La Figura 18 ilustra gráficamente esta correspondencia perfecta para el volumen, junto con la fuga promedio por quintil de actividad transaccional.

**Fig. 18:** Volumen reportado frente al calculado desde el detalle (izquierda) y fuga promedio por quintil de número de transacciones (derecha).

### 2.2.11 Decisiones de preprocesamiento derivadas del EDA

Los hallazgos anteriores determinan directamente el tratamiento de los datos previo al modelado, según se resume en la Tabla 14.

**Tabla 14:** Decisiones de preprocesamiento y hallazgo del EDA que las justifica.

| Hallazgo del EDA                                                                                                 | Decisión adoptada                                                                                                                                                           |
|------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Fuga casi determinada por <code>active_products</code> ( $R^2 = 0,767$ , escalera de paso constante)             | Auditar la construcción de la etiqueta; excluir <code>active_products</code> del conjunto de predictores o reportar por separado el desempeño con y sin ella                |
| Tres columnas transaccionales son duplicados desalineados o exactos (Tablas 4 y 13)                              | Eliminar <code>average_transaction_value</code> , <code>total_transaction_volume</code> y <code>avg_daily_transactions</code> ; conservar las verificadas contra el detalle |
| <code>credit_utilization_ratio</code> ausente exactamente cuando no hay tarjeta                                  | Crear indicadora <code>has_*</code> e imputar cero solo en clientes con tarjeta                                                                                             |
| Faltantes sin explicación en <code>complaint_topics</code> y <code>feature_requests</code>                       | Conservar únicamente la indicadora de presencia; no imputar el contenido                                                                                                    |
| Asimetría extrema en variables monetarias; $\rho_{\text{Spearman}} = 0,98$ entre CLV y volumen                   | Aplicar transformación $\log(1 + x)$ a montos y volúmenes; no eliminar atípicos                                                                                             |
| <code>satisfaction_score</code> y <code>nps_score</code> con $r = 0,917$                                         | Conservar una sola de las dos en modelos lineales                                                                                                                           |
| <code>occupation</code> (35 niveles) y <code>location</code> (18 niveles) de alta cardinalidad y baja frecuencia | Agrupar categorías poco frecuentes antes de la codificación <i>one-hot</i>                                                                                                  |

La aplicación de estas decisiones produce el conjunto `df_modelo`, de 48.723 filas y 54 columnas, sobre el cual se desarrollará la fase de modelado.

### 3 Conclusiones

Esta primera entrega tuvo como objetivo caracterizar el conjunto de datos y auditar su calidad antes de abordar el modelado predictivo de la fuga y del valor del cliente. El análisis exploratorio permitió describir las 54 variables de los 48.723 clientes y los 3,16 millones de transacciones asociadas, y verificar que ambas tablas son mutuamente consistentes: no existen clientes huérfanos, montos inválidos ni fechas nulas, y la cobertura transaccional es total. En ese sentido, el conjunto es apto para el modelado. No obstante, la auditoría reveló tres condiciones que habrían comprometido cualquier resultado obtenido sobre los datos crudos. La más relevante es la relación entre `churn_probability` y `active_products`: una escalera de paso exactamente constante que explica el 76,7 % de la varianza de la etiqueta y que, junto con el acotamiento artificial del rango, indica que la variable objetivo fue construida a partir de un predictor disponible. La segunda es la presencia de columnas transaccionales duplicadas y desalineadas, cuya naturaleza solo se hizo evidente al comparar las distribuciones como conjuntos y al reconciliarlas contra el detalle real de transacciones. La tercera es el carácter estructural de los valores faltantes de `credit_utilization_ratio`, que desaconseja la imputación por medidas de tendencia central. Estos hallazgos se tradujeron en un plan de preprocesamiento explícito y en el conjunto depurado `df_modelo`.

El estudio presenta limitaciones que conviene declarar. El análisis se apoya en un único con-

junto de datos cuyos indicios de generación sintética — rangos acotados, ausencia de estacionalidad semanal, paso constante en la escalera de fuga — limitan la validez externa de las conclusiones sustantivas sobre comportamiento financiero, aunque no afectan la validez del procedimiento de auditoría. Asimismo, no fue posible confirmar con la fuente cómo se construyó la etiqueta de fuga, por lo que la fuga de información se sostiene como la hipótesis más plausible y no como un hecho verificado. Como trabajo futuro inmediato, la Entrega 2 abordará el modelado propiamente dicho: la comparación de los modelos de referencia vistos en el curso frente a un modelo propuesto, evaluando el efecto de incluir o excluir `active_products` para cuantificar el impacto real de la fuga detectada, y utilizando el volumen transaccionado en escala logarítmica como predictor principal del CLV, dada la asociación monótona casi perfecta identificada en este análisis.

## Declaraciones

- **Disponibilidad de datos:** el conjunto es público y está disponible en Mendeley Data, <https://data.mendeley.com/datasets/mhb4zn3258/1> (DOI: 10.17632/mhb4zn3258.1), bajo licencia Creative Commons Attribution 4.0 Muñoz Guerrero et al. [2025].
- **Disponibilidad de código:** el código completo, incluido el cuaderno reproducible con el análisis exploratorio y sus resultados, está disponible en [https://github.com/RubenEsg/Machine\\_learning](https://github.com/RubenEsg/Machine_learning).
- **Contribución de los autores:** los tres autores participaron conjuntamente en el diseño del análisis, la implementación del cuaderno, la interpretación de los resultados y la redacción del manuscrito. Todos revisaron y aprobaron la versión final.
- **Conflicto de intereses:** los autores declaran no tener conflictos de interés.

## Referencias bibliográficas

- Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.
- Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.
- Sunil Gupta, Dominique Hanssens, Bruce Hardie, William Kahn, V. Kumar, Nathaniel Lin, Nalini Ravishanker, and S. Sriram. Modeling customer lifetime value. *Journal of Service Research*, 9(2):139–155, 2006.
- Shachar Kaufman, Saharon Rosset, Claudia Perlich, and Ori Stitelman. Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, 6(4):1–21, 2012.
- Roderick J. A. Little and Donald B. Rubin. *Statistical Analysis with Missing Data*. Wiley, Hoboken, NJ, 3rd edition, 2019.
- Luis Eduardo Muñoz Guerrero, Yony Fernando Ceballos, and Luis David Trejos Rojas. COFINFAD: Colombian fintech financial analytics dataset, 2025. Licencia CC BY 4.0. Disponible en <https://data.mendeley.com/datasets/mhb4zn3258/1>.
- John W. Tukey. *Exploratory Data Analysis*. Addison-Wesley, Reading, MA, 1977.

Wouter Verbeke, Karel Dejaeger, David Martens, Joon Hur, and Bart Baesens. New insights into churn prediction in the telecommunication sector: A profit driven data mining approach. *European Journal of Operational Research*, 218(1):211–229, 2012.

Rüdiger Wirth and Jochen Hipp. CRISP-DM: Towards a standard process model for data mining. In *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*, pages 29–39, 2000.